

K-HiveMind

AI 기반 실시간 말벌 사운드 탐지 및 경보 시스템

PRESENTER

AI 휴먼 교육센터 심화반 2조

DATE

2026-04-23



Contents

01 팀 소개 및 개발 개요

팀원 소개 및 업무 분담,
일정, 개발 개요

02 시스템 아키텍처

아키텍처 및 파이프라인,
프로세스

03 데이터 셋 & 모델 학습

데이터 처리 및 CNN 모델
학습, 특징 시각화

04 증강 기법 & 문제점

오디오/스펙트로그램/ImageDat
aGenerator 증강기법,
사운드 오염 및 계측기 문제

05 어플리케이션

앱 UI 및 시연

06 활용 방안 & 향후 계획

추후 활용 방안 및 계획

프로젝트 팀원 소개



김동현

팀장 / 서버 설계

서버 알고리즘 설계 및
개발
최적화 설계 총괄



반세윤

아키텍처 / 인프라

인프라 구축 및
인터페이스 개발
아키텍처 설계 총괄



임훈섭

데이터 사이언스

사운드 데이터셋 구축
및 AI 모델 학습 수행



구태민

UI/UX / 서버 연동

앱-서버 연동 및
실시간 알림 시스템
구축



이우진

UI/UX / 발표 자료
준비

앱 대시보드 개발 및
발표 자료 준비

PROJECT SCHEDULE

04/07~04/08

주제 선정 및 데이터 수집

Kaggle 및 유튜브 기반 말벌/꿀벌 사운드 수집, 주파수 도메인 특징 추출 및 분석



04/09~04/13

모델 설계 및 학습

아키텍처 설계, CNN 모델 설계 및 학습, 초기 모델 성능 검증, 시각화 분석



04/14~04/16

증강 및 고도화

오디오/스펙트로그램 증강 기법 적용 및 예측기 Bias 완화 전략 수립



04/17~04/21

시스템 통합 및 앱 개발

FastAPI 서버 구축 및 Android Flutter 기반 실시간 알림 앱 UI 연동 완료



04/22~04/24

발표 자료 준비 및 최종 테스트

발표 자료 준비, 최종 결과 도출 및 상용화 로드맵 발표 준비



말벌에 대한 꿀벌의 피해는 매년 증가하는 심각한 생태계 문제이다

말벌에 의한 피해는 꾸준히 증가하고 있습니다.

국내에서는 양봉 꿀벌 **10개 봉군**이 말벌의 공격을

받아 폐사하는 데 **단 1주일** 정도 걸리며, 2~3주면

50개의 봉군에 치명적인 피해를 입히며, 양봉

분야에서는 특히 8~9월 말벌들의 산란기에 무차별

공격으로 꿀벌 군집 파괴로 인해 연간 약 **1700억 원**

이상의 경제적 피해를 양봉 업계에 막중한 손해를

30~50%

군집 피해를

등검은말벌에 의한 꿀벌
군집 피해

300,000+

소방 출동 건수

연간 말벌 제거 소방청
출동 횟수

1,700억 +

경제적 피해

연간 양봉 업계 추정
손실액



2020년대 말벌 등장률 증가와 피해 금액 증가 추세

기후 변화와 생태계 변화로 말벌 출현이 증가하고, 양봉업계의 피해 금액도 지속적으로 늘어나고 있습니다.



말벌 등장률 (전국 평균)

2020년 100% → 2026년(E) **194%**

(2020년 대비 1.94배 증가)




피해 금액 (전국 합계)

2020년 830억 원 → 2026년(E) **1,700억 원**

(2020년 대비 +870억 원 증가)

연도별 말벌 등장률 및 피해 금액 추이



* 출처: 농촌진흥청, 산림청, 국민신문고 (2020~2023) / 2024년 이후는 추정치(E)

주요 시사점



말벌 등장률 지속 증가

2020년 100% →
2026년(E) 194%
(1.94배 증가)



피해 금액 지속 증가

2020년 830억 원 →
2026년(E) 1,700억 원
(+870억 원 증가)



조기 탐지 및 대응 중요

피해 확산과 금전적 손실을
줄이기 위한 스마트 모니터링
및 신속 대응 체계 필요



말벌 출현 증가로 인한 피해 규모가 매년 커지고 있으므로,
조기 탐지 시스템 도입과 신속 대응이 피해 최소화의 핵심입니다.

기존 탐지 방법의 한계

현재 말벌 탐지는 대부분 육안 관찰 및 신고 의존 방식으로 이루어집니다. 이는 전문 인력 부족, 늦은 탐지 시점, 야간·산간 지역 대응 불가 등의 문제를 야기합니다. 기존 트랩 방식은 설치 및 유지 비용이 높고, 비표적 곤충까지 포획하는 부작용이 있으며, 드론 기반 모니터링은 대규모 적용이 어렵습니다.



탐지 방법 탐지 정확도 실시간성 비용 효율성 확장성

육안 관찰	낮음	없음	높음	낮음
트랩 방식	중간	없음	중간	중간
드론 모니터링	높음	부분적	낮음	낮음
AI 기반 시스템	☑️ 높 음	⚡ 실 시 간	💰 중 간	🔍 높 음

📶 음향 모달리티의 강점

말벌 고유의 날갯짓 주파수(약 100Hz)를 분석하여 시각 정보 없이도 정밀한 탐지가 가능합니다.

야간 환경 탐지 성능 비교



👁️ 시각 탐지의 한계

카메라 기반 탐지는 야간, 안개, 폐쇄 공간 등 시야 제한 환경에서 성능이 급격히 저하되는 특성이 있습니다.


The diagram illustrates the architecture of the 'Overlord' system, which is designed for mobile app development and deployment. The system is built using a combination of cloud services, containers, and machine learning frameworks.

Key Components and Flow:

- User Interaction:** The system starts with an 'Overlord 사용자 [사용자]' (User) who interacts with the 'Overlord' mobile app (Vue, nodejs, gis). The app sends data to the 'nginx' web proxy and load balancer via 'khivemind.cloud'.
- Backend Services:** The 'nginx' proxy routes requests to the '오버로드 api' (Container: python, multithread) and the '오버로드 dashboard' (Container: Vue, nodejs, gis, spring boot). The '오버로드 api' is responsible for handling API requests, while the '오버로드 dashboard' provides a user interface.
- Data Storage:** The system uses '오버로드 서비스 정보 저장' (mongodb, NoSQL) for service information and 'bee sound' (file storage) for audio files.
- ML Pipeline:** The '오버로드 학습데이터 수집' (python: python) component collects data, which is then processed by '오버로드 학습데이터 전처리' (python: python). The preprocessed data is used for training and validation by '오버로드 학습데이터 트레이닝 및 검증' (python: python). The trained model is stored in the 'model 저장소' (Model Registry).
- Deployment:** The '오버로드 학습데이터 분석' (jupyter notebook: jupyter notebook) component analyzes the data, which is then processed by '오버로드 학습데이터 전처리' (jupyter notebook: jupyter notebook). The processed data is used for feature engineering by '오버로드 학습데이터 feature engineering' (jupyter notebook: jupyter notebook). Finally, the '오버로드 모델 설계' (jupyter notebook: jupyter notebook) component designs the model.
- CI/CD:** The system uses 'Github Actions' for Continuous Integration and Continuous Deployment. The 'Github Actions' (Continuous Integration) component manages the build process, including 'apk upload' and 'image upload' to 'DockerHub'. The 'Github Actions' (Continuous Deployment) component manages the deployment process, including 'pod service configmap들을 배포' (deploy pod service configmaps) and '배포 yml' (deploy yml).


The diagram also shows the roles of various developers: '오버로드 사용자 [사용자]' (User), 'AI 앱 개발자 [개발자]' (AI App Developer), and 'AI 서버 개발자 [개발자]' (AI Server Developer). The system is built using a combination of cloud services, containers, and machine learning frameworks.

AI 프로세스




사용한 데이터셋


항목	상세 내용
총 오디오 수	14,512개 (Train 70% / Val 15% / Test 15%)
수집 대상 종	(꿀벌, 자연 소리), (말벌)
데이터 소스	Kaggle Bee Audio, 유튜브




데이터셋 구성 비율



시간의 데시벨(dB) 특성 분석



꿀벌 - 복합적이고
퍼진형태의 진동




말벌 - 큰 진폭과
반복적인 주기 패턴



그러나 진폭의 차이는 “볼륨의 차이, 녹음 환경이나 장비”에 따라 쉽게 변할 수 있기 때문에, 파형만으로는 안정적인 구분 기준으로 사용하기 어려움

=> 신뢰도 높은 특징을 추출하기 위해 주파수 기반의 피쳐를 사용


시간 베이스 → 주파수 베이스로 변환한 특징 분석



꿀벌 - 주파수 대역이
평균 230Hz로
200이후에 잘 나타난다



말벌 - 주파수 대역이
평균 150 Hz로
200이전에 잘 나타난다



날갯짓 주파수는 주로 곤충의 체중과 날개 면적에 반비례

말벌은 꿀벌보다 체구가 크고 날개폭이 넓기 때문에 더 천천히 날갯짓해도 비행이 가능하며 그 결과 더 낮은 소리의 결과


⇒ 주파수 차이를 이용해 말벌 탐지 AI 모델을 학습

MFCC


- MFCC는 오디오 신호에서 추출할 수 있는 feature로, 소리의 고유한 특징을 나타내는 수치
- 주로 음성인식, 화자인식, 음성합성, 음악 장르 분류등 오디오 도메인의 문제를 해결하는데 사용

군집 분석 결과: MFCC로 주파수를 벡터화로 시켜 군집분석한 결과 Bee랑 Horner의 특징이 비슷해 서로 겹치는 현상 발생

데이터 분포 만을 기반

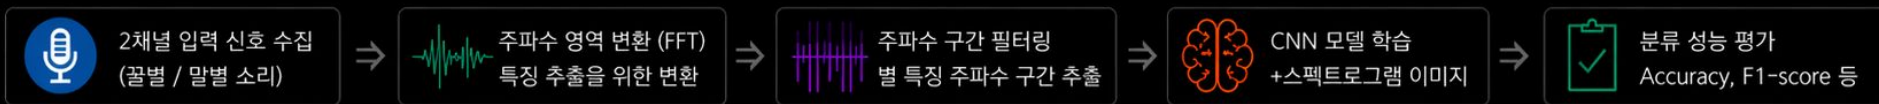




실제 클래스



AI 소음 진단 플랫폼 개발 과정 > 2) 소음 특징 추출 및 학습 데이터 생성

소음 특징을 추출하고 외부 노이즈를 최소화하기 위한 신호 처리 수행



신호 처리 최적화 실험 (Experiments A/B/C)

Experiment A

N_FFT	4,096
Hop Length	128
N_MELS	64

기본적인 주파수 해상도를
제공하나, 말벌의 미세한 고주파
패턴 식별에 한계가 있음.

Experiment B

N_FFT	4,096
Hop Length	128
N_MELS	128

OPTIMAL CHOICE

주파수 해상도 극대화를 통해
말벌 고유의 배음 (Harmonics)
패턴을 가장 명확하게 포착함.

Experiment C

N_FFT	2,048
Hop Length	256
N_MELS	128

시간 해상도는 우수하나, 주파수
분해능이 낮아 유사한 날개짓
소리와의 혼동 가능성 증가.

데이터와 이미지 전처리

기법 이름	기능	기대 효과
dB 변환 (Power → dB)	에너지 값을 로그 스케일로 압축	패턴 대비 증가, CNN 인식 안정화
하한 클리핑 (Min dB)	-80dB 이하 값 제거	배경 노이즈 제거, 학습 효율 향상
주파수 크롭 (Frequency Cropping)	핵심 주파수 대역만 선택	SNR 향상, 과적합 감소
적응형 크롭 (Adaptive Cropping)	Mel 크기에 맞춰 비율 기반 선택	다양한 환경에서 안정적 특징 추출

실전형 데이터 증강 전략 (Data Augmentation)

오디오 기반 증강	스펙트로그램 기반 증강	장비/환경 증강
Gain / Noise / Background Mixing	Time Shift / Time Masking	Device Style Augmentation
Pitch Shift / Time Stretch	Frequency Masking / Random Erasing	
효과: 환경 변화, 거리, 개체 차이 반영	효과: 특정 패턴 과의존 방지, 일반화 향상 다양한 변형을 통해 모델의 일반화 성능을 향상	효과: 녹음 장비 차이 대응, 실제 환경 적응



다양한 환경의 소리 데이터를 학습하여 실제 현장에서도 강건한 탐지 성능 확보

ImageDataGenerator 데이터 로드 및 증강 설정

10,000장이 있어도 비슷한 패턴이면 의미가 없다.

- 같은 위치, 같은 배경, 같은 밝기 -> 모델은 그냥 암기 (과적합)
- 이미지 데이터를 불러오면서 동시에 랜덤하게 변형해 학습용 데이터를 계속 만들어내는 기법
- 실시간으로 랜덤 변형(증강)을 수행하며 데이터 다양성을 증가시켜 모델의 일반화 성능 향상

ImageDataGenerator 기반 데이터 증강

제한된 학습 데이터를 다양한 형태로 변형하여 모델의 일반화 성능을 향상



증강 예시



Original (원본)



Rotation (원전)



Zoom (확대)



Flip (반전)


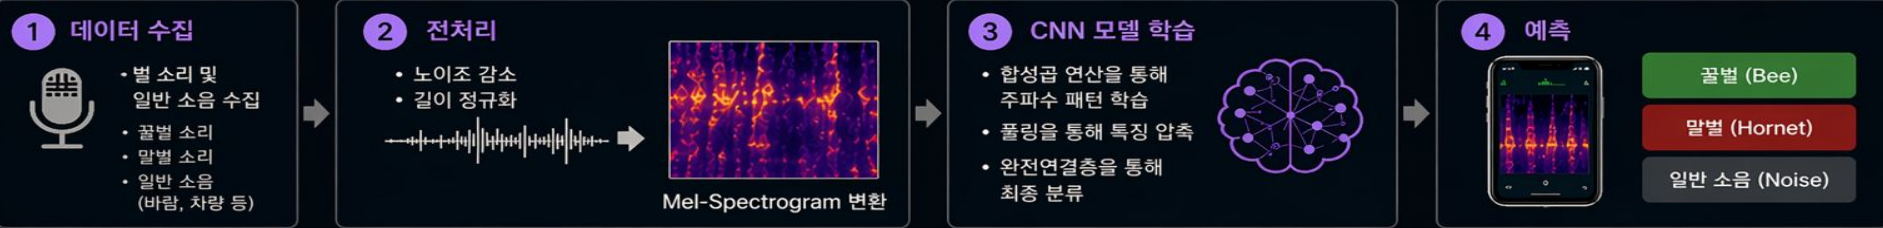
✓ 데이터 다양성 확보 → 모델의 과적합 방지 및 일반화 성능 향상



벌 소리 분류를 위한 CNN 모델 프로세스



벌(꿀벌, 말벌)과 일반 소음을 구분하는 합성곱 신경망(Convolutional Neural Network) 모델



모델 상세 구조

Layer (type)	Output Shape	Param #	Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 224, 224, 32)	896	conv2d_3 (Conv2D)	(None, 28, 28, 256)	295,168
max_pooling2d (MaxPooling2D)	(None, 112, 112, 32)	0	max_pooling2d_3 (MaxPooling2D)	(None, 14, 14, 256)	0
conv2d_1 (Conv2D)	(None, 112, 112, 64)	18,496	flatten (Flatten)	(None, 50176)	0
max_pooling2d_1 (MaxPooling2D)	(None, 56, 56, 64)	0	dense (Dense)	(None, 256)	12,845,312
conv2d_2 (Conv2D)	(None, 56, 56, 128)	73,856	dropout (Dropout)	(None, 256)	0
max_pooling2d_2 (MaxPooling2D)	(None, 28, 28, 128)	0	dense_1 (Dense)	(None, 2)	514

구조 설명

- Conv2D : 합성곱 연산을 통한 특징 추출
- MaxPooling2D : 특징 맵 축소 및 중요 특징 유지
- Flatten : 다차원 데이터를 1차원 벡터로 변환
- Dense : 분류를 위한 완전연결층
- Dropout : 과적합 방지

💡 CNN은 벌 소리의 주파수 패턴과 구조적 특징을 효과적으로 학습하여, 꿀벌·말벌·일반 소음을 **높은 정확도**로 구분할 수 있습니다.

Grad-CAM 기반 모델 해석


모델이 각 클래스의 어떤 주파수 패턴을 보고 판단하는지 시각적으로 분석



핵심 메시지


모델은 주파수의 절대적인 크기보다
패턴(규칙성, 불규칙성)과 위치에 집중합니다.

1 꿀벌 (Bee) Pred: Non_Hornet




저주파 영역에 주로 집중, 말벌보다 상대적으로 **고주파** 성분이 더 많고
주파수 패턴이 **불규칙적**이어서 모델이 학습하기 어려워하는 경향

2 꿀벌 (Bee) Pred: Non_Hornet




저주파 영역 중심, 고주파 성분이 일부 나타나지만
전체적으로 **불규칙한 패턴** → 모델 학습 난이도 ↑

3 No_Bee (배경/노이즈) Pred: Non_Hornet



특히 **고주파(상단)** 영역에서 **실루엣 shape**를 포착하여 판단

4 말벌 (Hornet) Pred: Hornet



꿀벌보다 더 **저주파** 영역에 주로 집중하고,
주파수 패턴이 **규칙적**이어서 모델이 명확하게 학습



해석 포인트



꿀벌(Bee)

저주파 영역을 중심으로 반응하지만,
말벌보다 상대적으로 **고주파** 성분이 많고
주파수 패턴이 **불규칙적**이어서
모델이 학습하기 어려워하는 경향



No_Bee (배경/노이즈)

특히 **고주파 상단** 영역에서
실루엣 shape를 보고 판단



말벌(Hornet)

꿀벌보다 더 **저주파** 영역에서
주파수 패턴이 **규칙적**으로 작용하여
모델이 명확하게 학습



종합 결론

✓ 모델은 단순 소리 크기가 아닌
주파수의 **위치와 패턴(규칙성/불규칙성)**을 기반으로 분류

✓ Grad-CAM을 통해 모델의 판단 근거를 시각적으로 확인하여
설명 가능한(Explainable) AI 구현이 가능




학습 성과 및 정도 검증 (Performance Results)

Train Acc = 0.99

Val Acc = 0.98

Training and Validation Accuracy




20 Epoch 학습 결과, **Training Accuracy 99%**
달성. 검증 데이터셋에서도 안정적인 수렴을 보이며
높은 일반화 성능을 입증

Train Loss = 0.05

Val Loss = 0.08


Training and Validation Loss



두 값 간의 차이가 크지 않아, 특정 데이터에 과적합되지
않고
전반적으로 안정적인 학습이 이루어진 것으로 판단

CONFUSION MATRIX ANALYSIS

Confusion Matrix



테스트 데이터셋 분석 결과, 말벌(Hornet) 클래스에
대한 **높은 재현율(Recall)**을 확보하여 실전 탐지 누락
가능성을 최소화

✔ 최종 모델 성능 검증 완료

Accuracy : 97% F1-Score : 97%

정적 / 동적 소음 검증결과


- 정적 소음 검증결과 “99% 적중”







모델 검증		precision	recall	F1-score	support	accuracy	Macro avg	Weight avg
	말벌	0.99	0.99	0.99	699	0.99	0.99	0.99
	정상	0.99	0.99	0.99	694	0.99	0.99	0.99

- 동적 소음 검증 결과 “82% 적중”

◆ 학습된 소음 유형에서 변형된 동적 소음을 예측한 결과 (※ 케이스 별 30번씩 테스트 수행)



동적 소음 검증결과 (Dynamic Test Results)







UI 화면 소개

메인 화면

설정 화면

위험 감지 화면

AI 결과 확인 화면



실시간 탐지 및 경보 어플리케이션 실행 화면 시연

실시간 푸시 알림

말벌 탐지 즉시 관리자 스마트폰으로 위험 경보를
발송합니다.

실시간 비디오 스트리밍 (추후 확장 가능)

현장의 CCTV 및 카메라 노드와 연동하여 탐지 상황을
실시간 영상으로 확인합니다.

활동 로그 및 통계 분석

과거 탐지 이력을 발생 횟수 및 위험 시간대를
시각화합니다.



본 시스템은 양봉업·산림청·지자체 등 다양한 분야에 적용 가능하다

개발된 말벌 감지 시스템은 단순 탐지를 넘어 생태계 보호, 농업 보호, 공공 안전 등 다양한 분야에 적용 가능합니다. 수집된 데이터로 말벌 특정 침입 시간, 계절을 파악해 사전에 예방 할 수 있는 방안을 마련합니다.



양봉 업

꿀벌 군집 보호 및 실시간 말벌 침입

감시 시스템 구축

📈 피해율 40% 감소 기대



산림 청

말벌 서식지 파악 및 생태계 데이터

수집

🛡️ 선제적 피해 방지



지자 체

공원, 학교 등 공공장소 내 말벌 위험

구역 안전 관리

👤 인명 사고 예방



농 업

수분 매개 곤충 보호를 통한 농작물

생산성 유지

🌿 생산성 안정화



연구기 관

생태계 사운드 데이터 아카이빙 및 학술

연구 지원

📄 학술 연구 기여



확장 가능성


CCTV 연동 및 스마트 시티 통합 관제

시스템 확장

🏠 스마트 시티 연계

말벌 감지 시스템 도입에 따른 기대 효과 및 경제적 가치 예측 수치화

시스템 도입 전후 연간 예상 피해액 비교 (단위: 억 원)



95% 단축

탐지 및 조기 대응 속도



50% 절감

현장 모니터링 노동력



약 3조 원

보호되는 화분매개 경제 가치

단순한 탐지를 넘어, 연간 **1,050억 원의 직접 손실을 방어**하고 약 3조 원 규모의 생태계 가치를 지키는 경제적 방어막입니다.

비즈니스 모델 관점에서의 활용 방안



핵심 가치 제언

- AI 기반 말별 접근
실시간 감지로
양봉 피해 예방 및
생산성 향상



고객 세그먼트

- 양봉 농가
- 스마트팜 운영자
- 농업 관련 기관
(지자체, 협회 등)



수익 모델

- IoT 디바이스 판매
(마이크 + 센서)
- 구독형 서비스
(AI 분석/알림)
- 데이터 기반 컨설팅
(말별 활동 분석 리포트)



핵심 자원

- 말별/꿀벌 사운드
데이터셋
- AI 음성 분류 모델
- 실시간 알림 시스템
(모바일 앱 / 웹)



핵심 파트너

- 농업-양봉 관련 기업
- IoT 하드웨어 업체
- 지자체 / 연구 기관
- 통신사 / 클라우드



사운드 수집
(활동 주변)



AI 분석
(별별 여부 판단)



실시간 알림
(모바일 앱)



신속 대응 및
피해 예방

사운드 기반 AI의 타 도메인 활용 방안



농업 / 축산

- 해충, 조류 감지
(벌레, 새, 두더지 등)
- 가축 이상 행동 감지
(소 울음, 돼지 소리 등)



산업 / 설비

- 기계 이상 소리 탐지
- 설비 고장 예측 및
예방 정비



모빌리티

- 차량 이상 소음 감지
- 엔진/브레이크 등
상태 분석



환경 / 재난

- 산불 조기 소리 감지
- 야생 동물 활동
모니터링



보안 / 안전

- 유리 깨짐, 비명 등
위험 소리 감지
- 침입/이상 행동 탐지



사운드 기반 AI는 농업을 넘어 산업, 환경, 보안 등
다양한 분야로 확장 가능한 기술입니다.



AI 기술과 사운드 분석의 결합은 **실시간 감지, 예측, 대응의 새로운 가치**를 창출하며,
양봉 산업의 지속 가능성과 다양한 산업 분야의 디지털 전환을 이끄는 **핵심 동력**이 됩니다.

향후 로드맵과 상용화 전략

비즈니스 상용화시 2027년 하반기를 목표로 단계적 개발 로드맵을 수립하였습니다. 모델 고도화부터 전국 현장 검증 확대, 그리고 글로벌 시장 진출까지의 지속 가능한 비즈니스 모델을 구축합니다.



2026 Q1~Q2

모델 고도화 및 개발

AI 모델 성능 최적화 및
하드웨어/소프트웨어 통합
개발 완료



2026 Q3~Q4

현장 테스트 확대

전국 30개소 주요 양봉장
및 위험 지역 대상 실증
사업 추진



2027 Q1~Q2

플랫폼 공식 출시

앱 마켓 등록 및 상용
서비스 개시, 본격적인
시장 진출 준비



2027 Q3~Q4

글로벌 시장 진출

말벌 피해가 심각한 해외
국가 타겟팅 및 글로벌
서비스 확장

결론 및 핵심 성과 요약

말벌 사운드 감지 프로젝트는 **AI 기술을 활용**하여 기존 방법의 한계를 극복하고, **실시간·고정밀·저비용**의 말벌 탐지 솔루션을 제공합니다. 본 시스템의 상용화는 양봉업 피해 최소화, 공공 안전 강화, 농업 생산성 보호에 크게 기여할 것입니다.



97%

탐지
정확도



2초 이내

실시간 탐지
지연 시간



Edge-Device

저전력 디바이스
구동 최적화



2027년

국내외 상용화
최종 목표

팀원 자체평가

	역할	잘한 점	아쉬운 점	개선점	느낀점
김동현	팀장	백엔드 서버 API 개발, 시스템 구조 기획, 앱 스토리보드 제작	API 보안 및 인증 체계의 단순함	모델의 노이즈 저항성 강화, 시스템 성능 최적화	FAST API 통신 경험, 추론 서버 구현 경험
반세윤	팀원	AI모델 플랫폼 설계 구축, 주제 관련 연구 탐색, 모델 검증 테스트	말벌 데이터 수집에 대한 어려움	MLops와 드리프트 적용, 서비스를 위한 다중 모델 적용	소리 관련 처리 경험, CNN모델 실사용 경험, AI 플랫폼 구축 경험
임훈섭	팀원	다양한 음성 데이터 튜닝, 여러 특성과 기법 도입, 모델 성능 향상	저품질의 데이터셋, 계측기 음질에 따른 데이터 패턴의 무일관성	Ablation study와 최적의 피쳐와 하이퍼 파라미터를 못 찾음	데이터 처리, 피쳐 개발, AI 모델 성능 문제해결 능력 향상
구태민	팀원	컨셉에 맞게 UI/UX 개발, 서버 메모리 부하 문제 주파수 임계값 설정으로 1차 필터링	Edge Device 성능, Firebase와 Android의 호환 문제	Terminated 상태일때 Data-only 메시지 FCM 알림으로 받지 못 함	WBS 기반 실무 프로젝트 경험으로 프로세스 숙지, AI 모델을 앱에 적용 경험
이우진	팀원	앱 대시보드 개발, 이미지 자료 확보, 발표 자료 생성	에뮬레이터 성능 한계, AI 학습 모델 부족	학습 모델 강화 필요, 시스템 아키텍처, 서버 설계 강화 필요	AI 활용 프로젝트 경험, 센서-AI모델-서버-앱 연동 프로세스 파악

문제점 분석 요약 및 개선 가설

현상 분석: 계측기 의존성

말벌(유튜브)과 꿀벌(일관된 장비) 간의 데이터 소스 차이로 인한 장치 Bias 발생 확인. 특정 장비의 노이즈 패턴을 학습했을 가능성 상존

개선 가설: 환경 일반화

동일 계측기로 현장 데이터를 수집하여 재학습할 경우, 장치 특징이 아닌 실제 사운드 패턴 학습 가능. 일반화 성능 대폭 향상 기대

- **동일 계측기 기반 데이터 수집**

- 정상/말벌/소음 전 클래스를 동일 장비로 현장 수집

- **Hard Negative 데이터셋 강화**

- 말벌 유사 주파수 대역의 소음을 집중 수집하여 Non-Hornet 학습

- **전처리 파이프라인 일원화**

- 동일 샘플링(32kHz) 및 전처리(Mel-Spectrogram) 파이프라인 적용

- **현장 환경 반영한 모델 파인튜닝**

- 학습 모델을 현장 데이터로 미세 조정(Fine-tuning)

Future Improvement Plan: Bias Mitigation

Data Diversity: 장치 차이를 의도적으로 혼합하여 클래스 불균형 해소

튜닝중

Robust Split: 동일 원본 장치 단위로 Train/Test 분리 (일반화 성능)

Pre-processing: 전처리 과정에서 장치 고유 흔적(Bias) 제거 강화

튜닝중

Augmentation: 세로 Artifact 반응 억제를 위한 Masking 기법 적용

튜닝중

Validation: 장치 분류 실험을 통한 모델의 의존성 정밀 검증

Q&A



프로젝트에 관한 궁금한 점을 자유롭게 질문해 주세요.



TEAM

AI 휴먼교육센터 심화반
2조



EMAIL



LOCATION

AI Human Education
Center

THANK YOU FOR YOUR ATTENTION